

論文題目 (暫定): 基於時空樞紐階層聚合與經驗路徑重建之人流連鎖影響預測框架

第一章 緒論 (Introduction)

【三個核心創意點 (Innovation Points)】

- 創意 A (方法論創新): 階層式空間聚合 (Hierarchical Spatial Aggregation) - 結合平滑化與自適應 HDBSCAN, 解決原始 GPS 軌跡雜訊過多無法直接對齊的問題。
- 創意 B (方法論創新): 經驗路徑重建 (Empirical Routing Reconstruction) - 捨棄傳統機率預測, 改以真實時空重疊 (Spatiotemporal Co-occurrence) 進行確定性的連鎖追蹤。
- 創意 C (應用面創新): 主動式連鎖影響模擬 (Proactive Cascading Simulation) - 運用於交通地標封閉的情境模擬 (What-If) 與疫情次級傳播的事前預警。

1.1 目標領域與問題定義

隨著智慧城市的發展, 掌握人群移動軌跡對於城市韌性 (如疫情預警與交通規劃) 至關重要。這類大尺度的人流追蹤能有效協助政府與企業進行資源重分配。舉例來說, 當城市中某個重要交通樞紐 (POI) 因施工必須封閉, 或是某個商場爆發傳染病時, 我們必須精準預估「這件事將會影響到哪些人? 這些人隨後又會將影響 (如交通壅塞或病毒) 帶往哪些次級地點?」。在此情境下, 輸入為海量使用者的歷史移動軌跡, 輸出則為受連鎖影響的群體規模與路徑分佈。

1.2 過去方法的侷限性

過去, 針對數位接觸者追蹤 (Digital Contact Tracing) 或軌跡重疊問題, 學者多採用基於原始 GPS 座標的「點對點 (Point-to-Point)」交集演算法或圖神經網路 (如 DeepTrace 等)。然而, 這類方法在應用於大尺度目標問題時面臨嚴重侷限: 首先, 直接計算千萬級節點的交集會引發極高的運算成本 (Computational Cost); 其次, 這類系統多屬於事後通報的被動監測, 受限於微觀視角, 難以主動預測人群移動在整體空間網絡中引發的「連鎖效應 (Cascading Effects)」。

1.3 本論文提出之核心理念

為克服前述方法的運算瓶頸與被動性, 本論文提出「時空樞紐連鎖影響 (Spatiotemporal Hub Cascading Impact)」分析框架。此概念的核心是: 人類的移動並非隨機, 而是高度圍繞特定的「生活圈 (Hubs)」。

有了這個核心概念, 我們將運算從「點對點」提升至「樞紐對樞紐 (Hub-to-Hub)」。

透過建立全局生活圈網路, 我們不僅能將運算維度指數級降低, 還能利用經驗路徑重建 (Empirical Routing Reconstruction) 精準找出群體間的確定性連鎖路徑, 補足過去缺乏全局連鎖預測的缺點。

1.4 資料集嫁接與前處理設計

儘管我們的概念是基於「生活圈網路」, 但現實中蒐集到的原始軌跡資料 (Raw Data) 充滿微觀擾動與定位漂移, 無法直接應用於本概念。因此, 我們提出了「階層式空間聚合 (Hierarchical Spatial Aggregation)」作為嫁接方法。我們利用滑動中位數 (Rolling Median) 平滑化結合自適應 HDBSCAN, 將高維度且充滿雜訊的連續軌跡, 合理且物理性地收斂為離散的全局核心生活圈 (Global Hubs), 藉此弭平原始資料與核心演算法之間的落差。

1.5 整體運作流程總結

綜合上述所言，本論文演算法的大致概念流程如下：



[原軌跡資料] -> [軌跡平滑與自適應叢集去噪] -> [階層式全局樞紐(Global Hubs)建置] -> [經驗路徑連鎖追蹤] -> [Primary/Secondary 影響評估]

依序進行資料降噪、離線網路建置，最後於線上進行情境模擬查詢。為了驗證本方法的有效性，我們使用了 [填入資料集名稱/規模] 的真實軌跡資料集進行實驗。

1.6 章節架構

本論文後續章節安排如下：第二章將進行相關文獻探討；第三章描述實驗所用之資料集與前處理細節；第四章詳述核心演算法模組與數學定義；第五章展示實驗結果與效能量化分析；第六章則為結論與未來展望。

第二章 文獻探討 (Related Work)

2.1 軌跡壓縮與去噪 (Trajectory Compression and Denoising)

- 原理與現有研究：原始 GPS 資料具有高度冗餘性。傳統研究如 Douglas-Peucker 演算法，或近期的 DETECT 深度神經網路分群模型，主要針對軌跡的幾何特徵或時空相似度進行壓縮。
- 與本論文之差異/缺點：這些方法多著重於「單一軌跡」的空間降維，缺乏對「多使用者共用生活圈 (Semantic Hubs)」的全局對齊能力。本研究提出的階層式聚合不僅去噪，更將座標轉化為具備拓撲意義的 Global Hubs。

2.2 人流移動模型與預測 (Human Mobility Modeling)

- 原理與現有研究：研究指出人類移動具有高度規律性。許多學者利用馬可夫鏈 (Markov Chains) 或次要興趣點推薦系統 (Next-POI Recommendation) 來建立歷史轉移機率矩陣，以預測人群動向。
- 與本論文之差異/缺點：機率模型在本質上屬於「統計猜測」，容易在多層連鎖預測中產生極大的誤差累積。本研究捨棄機率猜測，改採「經驗路徑重建 (Empirical Routing)」，僅追蹤實際發生的時空重疊，確保連鎖影響的確定性。

2.3 疫情接觸追蹤與連鎖影響 (Contact Tracing and Cascading Impact)

- 原理與現有研究：數位預警系統 (如 COVID-19 期間的藍牙/GPS追蹤) 透過廣度優先搜尋 (BFS) 或深度圖神經網路 (如 DeepTrace) 尋找感染源或潛在接觸者。
- 與本論文之差異/缺點：這類數位追蹤系統面臨「點對點」運算成本過高 (Computational Cost) 的問題，且只能針對「已發生」的事件進行回溯。本研究的系統具備 What-If 情境模擬能力，能在事件發生前主動推演 Secondary Impact。

第三章 資料集描述 (Dataset Description)

3.1 資料來源與範圍

(請根據你的實際資料填寫)。本研究採用 [OOO 資料集]，資料涵蓋時間為 [X天/月]，空間範圍落在 [OOO 區域]。資料格式為數值型，包含使用者匿名ID (UID)、天數 (d)、時間戳記 (t) 以及空間座標 (X, Y)。

3.2 資料集觀察與特性

本資料集的挑戰在於其屬於「連續的數值型定位資料」。透過統計性描述可發現，使用者的原始軌跡具有高度的定位跳動 (微觀隨機性)。

3.3 資料前處理 (Data Preprocessing)

針對上述資料雜訊問題，我們採用了滾動視窗平滑化 (Smoothing Window = 5)，以中位數濾除極端的離群值 (Outliers)。此步驟能有效保留使用者的核心停站點，為後續的空間叢集演算法提供穩定的輸入特徵。

第四章 演算法 (Methodology)

4.0 整體演算法細節流程介紹

本框架分為「Offline (離線建置訓練)」與「Online (線上查詢使用)」兩大階段。

4.1 第一階段：階層式空間聚合模型 (Offline Build)

- 輸入與輸出：輸入為全體使用者的平滑化軌跡；輸出為全域字典 `global_hubs` 與事件紀錄表 `event_log`。
- 模型架構與物理意義：

1. 自適應 **HDBSCAN** 層：利用不同的最小叢集大小 ($\text{min_cluster_sizes}=[15, 10, 5, 3]$) 進行降羣擬合。其物理意義在於確保「高密度商圈」與「低密度住宅區」的生活圈皆能被動態捕捉。
2. 凝聚分群層 (**Agglomerative Clustering**)：將各使用者的 Local Hubs，透過搜尋半徑 K (merge_dist) 進行合併。其物理意義為「將不同使用者但地理位置極度相近的活動熱區，對齊至同一個全域地標 (Global Hub)」。

4.2 第二階段：經驗路徑與連鎖追蹤模型 (Online Query)

- 輸入與輸出：輸入為目標地標 G_{target} 與時間區間；輸出為受第一層影響的使用者名單 ($Primary_Impact$) 與受第二層連鎖影響的使用者名單 ($Secondary_Impact$)。
- 作法描述 (對應程式碼邏輯)：
 1. 初級影響過濾：於 event_log 中檢索在指定時間內造訪 G_{target} 的個體，記錄其暴露時間 t_{exp} 。
 2. 次級連鎖追蹤：追蹤初級使用者在 t_{exp} 之後的實際移動路徑 (經驗路徑)。若他們在時間 t_{sub} 移動至新的地標 G_{new} ，且該地標同時存在其他未感染之個體，則將這些新個體標記為次級影響目標。(註：此段可用數學集合符號 $U_{primary} \cap U_{sync}$ 來改寫，增加學術感)。

4.3 演算法檢驗之 KPI (量化指標)

- 資料降維率 (**Dimensionality Reduction Ratio**)：計算演算法將 N 個原始 GPS 座標壓縮為 M 個 Global Hubs 的比例，用以證明計算複雜度大幅降低。
- 連鎖檢索延遲 (**Query Latency**)：紀錄線上追蹤 Primary 到 Secondary 的毫秒數，證明其具備即時預警的價值。

第五章 實驗模擬 (Experiments)

5.1 資料集介紹 (略，承接第三章)

5.2 實驗 Setting

- 超參數設定：包含平滑化視窗 $W = 5$ 、聚合半徑 $K = 2$ 到 $K = 8$ 的設定。
- 比較對象 (**Baselines**)：將本方法與「未經壓縮的原始 GPS 點對點交集法 (Brute-force)」或「傳統 DBSCAN 單層分群」進行比較。

5.3 最佳參數數量的選擇 (Parameter Sensitivity)

探討合併半徑 K 值的變化對 Global Hubs 數量的影響。(需附圖：X軸為 K 值，Y軸為 Hub 總數的走勢圖。描述其呈 L 型收斂的趨勢，證明演算法的穩定性)。

5.4 質化分析：What-If 情境模擬案例

挑選特定地標 (如 G10) 進行封閉模擬。說明演算法成功找出了主要影響路徑與次級影響網路。(在此處放入你截圖中的「影響追蹤結果 (混合路徑) - Impact Tracing for G10 on Day 10」視覺化圖表，並解釋紅線與黃線的物理意義)。

第六章 結論 (Conclusion)

6.1 Introduction 的濃縮

本領域在公共衛生與交通預警上至關重要。過往的方法受限於點對點計算，面臨運算成本高昂且無法主動預測的困境。為此，我們提出了基於階層式空間聚合與經驗路徑重建的「時空樞紐連鎖影響」分析框架。實驗結果證實，本方法不僅巨幅降低了資料儲存與檢索成本，更成功將單點的被動接觸史追蹤，昇華為具備全局視野的主動式連鎖影響預測模型。

6.2 未來工作 (Future Work)

未來的研究可針對本論文目前無法做到的部分進行擴充。例如：目前的經驗路徑重建依賴靜態的歷史 Event Log，未來可結合即時的串流資料庫 (Streaming Database)，讓 Global Hubs 能隨著城市突發事件進行動態的拓撲更新；此外，亦可引入外部環境變數 (如天氣、路網容量限制) 以進一步強化交通情境模擬的精確度。